CASO DE ESTUDIO · APRENDIZAJE AUTOMÁTICO II

Informe de Resultados - Modelado y generación de *Insights* en la industria azucarera: Caña en el Ingenio Providencia

> *Predicción de TCH y %Sac.Caña (regresión) y clasificación de niveles de productividad bajo, medio y alto*

Autores:
Daniel Velasco López, Juan David Martínez Legarda, Juan Esteban Cardona García, y Katherin Adriana Camargo Cetina.
Profesor: Aníbal Sosa
Aprendizaje Automático II · Maestría en Inteligencia Artificial Aplicada · Universidad Icesi, Cali, Colombia
Fecha: 22 de noviembre de 2026
Repositorio: github.com/juanestebancg2806/sugarcane-yield-quality-prediction – Notebooks "03…"

LOS RESULTADOS EN CUATRO CIFRAS

47 %
VARIACIÓN EXPLICADA
de TCH y %Sac.Caña con XGBoost + historial (R^2 0.472 y 0.465); la regresión lineal llega a 30–32 %

≈14 %
ERROR EN TONELAJE
error medio (MAE) de 17.65 t/ha sobre un TCH promedio de 130 t/ha

≈5 %
ERROR EN SACAROSA
error medio (MAE) de 0.646 puntos sobre una sacarosa promedio de 12.4 %

1.3–1.5×
CLASIFICACIÓN
F1 macro de la logística L1 (0.434 / 0.480) frente al azar (≈0.32) al ubicar lotes en bajo, medio o alto

QUÉ ENCONTRAMOS

1. Tonelaje (TCH)

Lo explican el **rendimiento del corte anterior**, la **edad** del cultivo, el **número de corte** y la **variedad**.

El TCH cae de 141 t/ha en plantilla a 126.5 t/ha desde el cuarto corte.

2. Sacarosa

Manda el **calendario**: máxima en septiembre (12.84 %) y mínima en junio (11.77 %).

La **dosis y las semanas de madurante** suben la sacarosa; la **lluvia previa** la diluye.

3. Niveles bajo / medio / alto

Una **regresión logística sencilla** iguala a Random Forest, XGBoost y SVM, y es más fácil de explicar.

La mayoría de errores ocurre entre **clases vecinas**.

Resumen

Este informe modela la productividad del Ingenio Providencia con dos bases de datos: HISTORICO_SUERTES (21 027 cosechas, 2017–2024), para predecir por regresión las toneladas de caña por hectárea (TCH) y el porcentaje de sacarosa (%Sac.Caña), y BD_IPSA_1940 (2187 cosechas de la variedad CC01-1940), para clasificar ambos indicadores en niveles bajo, medio y alto. Se compararon modelos de referencia (regresión lineal, Ridge, Lasso, logística multinomial L1 y KNN) con Random Forest, XGBoost y SVM, con y sin el historial del lote. La partición 80/20 se agrupó por hacienda o por periodo, y la validación cruzada de cinco pliegues se hizo solo sobre el entrenamiento.

En regresión ganó XGBoost con historial: R^2 en prueba de 0.472 para TCH (RMSE 23.11 t/ha) y de 0.465 para sacarosa (RMSE 0.837 puntos), frente a 0.304 y 0.316 de la regresión lineal. En clasificación, ningún modelo complejo superó de forma consistente a la logística L1 (F1 macro de 0.434 y 0.480), que se eligió por su estabilidad e interpretabilidad. Los factores clave fueron el rendimiento del corte anterior, la edad, el número de corte, la variedad, el mes de cosecha y el madurante. Los modelos sirven para planear la molienda y priorizar lotes, pero comprimen los extremos y pierden precisión ante años nuevos.

1 Introducción

El problema de negocio y los objetivos del estudio

EN PALABRAS SIMPLES

Queremos anticipar, antes del corte, cuánta caña dará cada lote y cuánto azúcar tendrá, para programar mejor la cosecha, el madurante y el molino.

El Ingenio Providencia, en el valle del río Cauca, planea su operación con dos indicadores: el TCH, que define cuánta caña llega al molino, y el %Sac.Caña, que define cuánta azúcar se extrae de cada tonelada. Ambos dependen de la variedad, la edad, el número de corte, el clima y la maduración. Como su correlación es baja (−0.17), cada indicador necesita su propio modelo. Los objetivos fueron: (i) comparar modelos de regresión para TCH y %Sac.Caña; (ii) comparar modelos de clasificación en tres niveles; (iii) interpretar los factores con sentido agronómico; y (iv) elegir el mejor modelo por tarea con una validación que simule lotes y periodos no vistos.

2 Metodología

Datos, modelos, validación y métricas

EN PALABRAS SIMPLES

Separamos desde el inicio un 20 % de haciendas (o de meses) que los modelos nunca vieron y solo lo usamos al final. Así, la evaluación final simula cómo funcionaría el modelo en lotes nuevos.

2.1 Datos y variables predictoras

HISTORICO_SUERTES: 21 027 cosechas (2017–2024; 926 haciendas, 5799 lotes), con 20 672 registros válidos para TCH (se excluyeron 355 con menos de 60 t/ha) y 20 578 para sacarosa. Solo se usaron predictores conocidos antes o al momento del corte: edad y número de corte, madurante (dosis y semanas), lluvias por ventanas del ciclo [1], riego, rasgos del lote (zona, suelo, distancia, variedad, tenencia) y de la cosecha (tipo de corte, quema, cultivo, destino semilla, año y mes).

BD_IPSA_1940: 2187 cosechas de CC01-1940 (2014–2021; 285 haciendas, 72 periodos). Las clases siguen los umbrales del Ingenio: TCH bajo <125, medio 125–150 y alto >150 t/ha; sacarosa baja <12.2, media 12.2–13.0 y alta ≥13.0 %. Se usaron siete predictores: edad, cortes, semanas y dosis de madurante, lluvia (imputada por mes), mes (con armónicos, porque la sacarosa sigue el calendario de lluvias [3]) y tenencia, con VIF máximo de 2.82. El % de *Diatraea* quedó fuera porque se mide en la cosecha [2].

2.2 Estrategia de modelado

Modelos. Como referencia, la regresión lineal múltiple, Ridge y Lasso en regresión, y la logística multinomial con regularización L1/L2 y KNN con k optimizado (k = 19 en TCH y 47 en sacarosa) en clasificación. Como modelos avanzados, Random Forest, XGBoost y, en clasificación, SVM con kernel RBF, porque capturan relaciones no lineales e interacciones entre clima, variedad y manejo. Todos se probaron también con el historial del lote (resultado del corte anterior).

Validación. La partición 80/20 se hizo al inicio y se agrupó para evitar fugas de información: por hacienda en suertes (740 haciendas en entrenamiento y 186 en prueba) y por periodo en IPSA con StratifiedGroupKFold [4] (56 y 16 periodos). Los hiperparámetros se ajustaron con GridSearchCV y validación cruzada de cinco pliegues agrupados, solo sobre el entrenamiento (en IPSA, repetida tres veces: 15 pliegues). Métricas: R^2, RMSE y MAE en regresión; Accuracy, F1 macro, Kappa y matriz de confusión en clasificación. En IPSA, un modelo debía superar a la logística en al menos 12 de 15 pliegues para ser elegido.

3 Resultados y discusión

Comparación de modelos, coeficientes e importancia de variables

3.1 Regresión: TCH y %Sac.Caña

EN PALABRAS SIMPLES

El mejor modelo se equivoca en promedio unas 18 t/ha (≈14 %) en tonelaje y 0.65 puntos (≈5 %) en sacarosa. Saber cómo rindió el lote en su corte anterior es la pista más útil.

Tabla 1. Modelos de regresión: desempeño en prueba y R^2 en validación cruzada (CV)

Modelo	TCH RMSE	TCH MAE	TCH R^2	TCH R^2 CV	%Sac RMSE	%Sac MAE	%Sac R^2	%Sac R^2 CV
Media constante	31.83	25.19	−0.001	−0.005	1.146	0.905	−0.002	−0.002
Regresión lineal	26.53	20.40	0.304	0.267	0.946	0.731	0.316	0.335
Ridge	26.51	20.41	0.306	0.268	0.947	0.731	0.316	0.335
Lasso	26.55	20.43	0.304	0.268	0.947	0.731	0.315	0.336
Random Forest	25.47	19.75	0.359	0.329	0.869	0.676	0.423	0.424
XGBoost	24.66	18.98	0.399	0.341	0.845	0.653	0.455	0.450
Reg. lineal + historial	25.06	19.19	0.380	0.317	0.926	0.714	0.345	0.356
Random Forest + historial	23.49	18.01	0.455	0.404	0.863	0.670	0.431	0.428
XGBoost + historial (elegido)	**23.11**	**17.65**	**0.472**	**0.422**	**0.837**	**0.646**	**0.465**	**0.457**

XGBoost con historial fue el mejor en ambos indicadores: su MAE equivale a cerca del 14 % del TCH medio (130.2 t/ha) y al 5 % de la sacarosa media (12.4 %). El bootstrap por hacienda confirma que la mejora frente a la regresión lineal es real: −3.42 t/ha de RMSE en TCH (IC95 [−4.74, −2.11]) y −0.109 puntos en sacarosa ([−0.133, −0.086]). La Figura 1 muestra que las predicciones se comprimen hacia la media: el 20 % de lotes con menor TCH se sobrestima en 24.5 t/ha y el 20 % con mayor TCH se subestima en 23.6 t/ha. Los lotes de semilla (errores de 39–42 t/ha) no son aptos para el modelo.

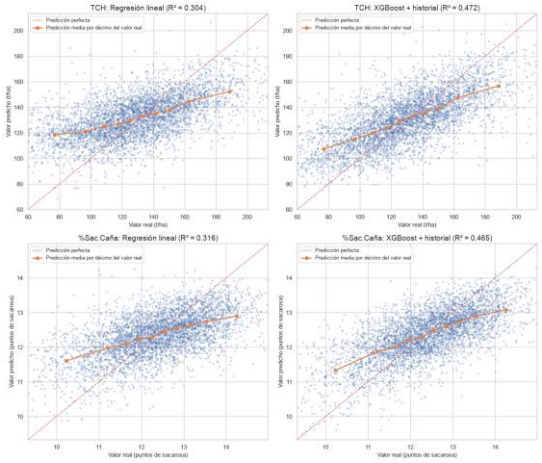


Figura 1. Valores reales frente a predichos en prueba: regresión lineal y XGBoost + historial

Coeficientes de la regresión lineal (errores agrupados por hacienda [5]). En TCH, cada mes de edad suma 5.20 t/ha (p<0.001) y cada corte resta 0.52 t/ha (p=0.0001), por el declive de las socas [6]; la dosis de madurante suma 2.85 t/ha (p=0.0067); la lluvia de 3–6 meses antes del corte resta 0.84 t/ha por cada 100 mm (p=0.006) y la de los dos meses previos suma 1.97 (p=0.0012). Los lotes de semilla rinden 21.75 t/ha menos y, frente a CC01-1940, CC05-430 suma 14.2 t/ha y CC85-92 resta 19.2. En sacarosa domina el manejo: cada L/ha de madurante suma 0.48 puntos (p<0.001), la lluvia de los dos meses previos resta 0.15 puntos por cada 100 mm (dilución), y frente a enero septiembre y octubre suman 0.65 puntos y junio resta 0.48 [1]. La autocorrelación entre cortes del mismo lote (Durbin-Watson 1.35) motivó incluir el historial; como los residuos no son normales ni homocedásticos, los p-values se leen con cautela.

Importancia de variables. Según la importancia por permutación (Figura 2), en TCH pesan más el TCH del corte anterior, la edad, el período, el número de corte y la variedad; en sacarosa, el período de cosecha y la dosis y semanas de madurante. Según la dependencia parcial, el TCH baja de 141 t/ha en plantilla a 126.5 desde el cuarto corte, el madurante actúa desde cerca de 0.6 L/ha con efecto completo a las 7–10 semanas [7] y la sacarosa va de 11.77 % en junio a 12.84 % en septiembre.

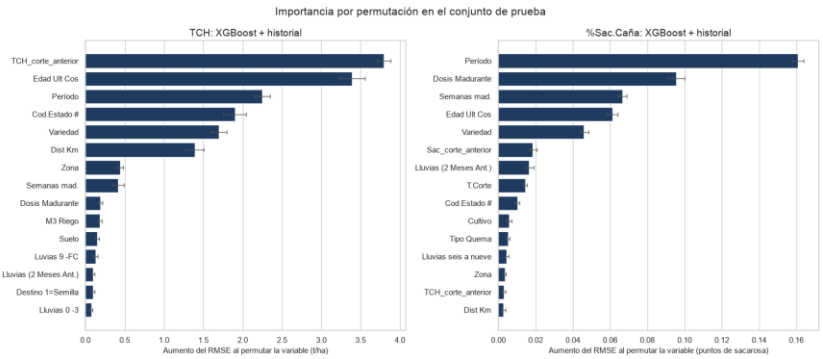


Figura 2. Importancia por permutación de las variables en prueba (XGBoost + historial)

3.2 Clasificación: niveles de TCH y sacarosa (CC01-1940)

EN PALABRAS SIMPLES

Clasificar un lote en bajo, medio o alto es más difícil: los modelos aciertan más que el azar, pero la mayoría de errores son entre clases vecinas. La logística, un modelo sencillo, funciona igual de bien que los complejos.

Tabla 2. F1 macro y Kappa de los clasificadores en validación cruzada (CV, 15 pliegues) y prueba

Modelo	TCH F1 CV	TCH F1 prueba	TCH Kappa prueba	Sac F1 CV	Sac F1 prueba	Sac Kappa prueba
Logística L1 (elegido)	**0.413**	**0.434**	**0.181**	**0.435**	**0.480**	**0.247**
KNN	0.365	0.371	0.076	0.426	0.430	0.166
Random Forest	0.416	0.436	0.166	0.435	0.483	0.220
XGBoost	0.415	0.438	0.171	0.435	0.516	0.267
SVM	0.413	0.403	0.138	0.420	0.479	0.229
Logística + historial	0.434	0.456	0.210	0.434	0.484	0.243
Random Forest + historial	0.440	0.480	0.230	0.440	0.486	0.227
XGBoost + historial	0.428	0.448	0.174	0.438	0.498	0.251

Todos los modelos superan los pisos (F1 de 0.17 con la clase más frecuente y de 0.32 con el azar), pero la discriminación es moderada (Kappa entre 0.15 y 0.25). En validación cruzada, ningún modelo complejo sin historial superó a la logística en más de 8 de 15 pliegues en TCH, ni en más de 9 en sacarosa. Las mejores cifras puntuales en prueba (XGBoost en sacarosa, F1 0.516) no se sostuvieron en validación, que es el criterio de elección; con pocos predictores y señal débil, es habitual que la logística iguale a modelos más flexibles [8]. Se eligió la logística multinomial L1 (accuracy en prueba de 0.451 en TCH y 0.533 en sacarosa) y, para TCH, se recomienda su versión con historial, que ganó en 14 de 15 pliegues (F1 0.456, Kappa 0.210). Los errores se concentran entre clases vecinas (Figura 3).

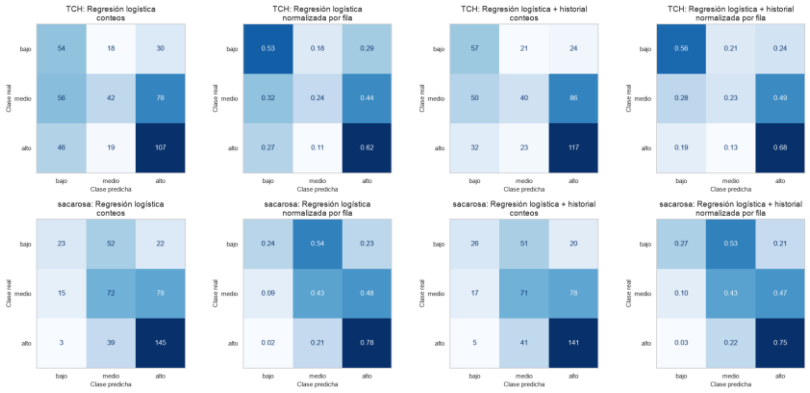


Figura 3. Matrices de confusión en prueba: logística L1 elegida y logística + historial

Coeficientes de la logística (clase baja frente a alta, por desviación estándar). En TCH, L1 elimina 5 de 11 columnas; el número de cortes es el factor más fuerte (OR 1.49 hacia la clase baja) y la edad protege (OR 0.885). En sacarosa domina el calendario (coseno anual, OR 0.509): junio empuja hacia la clase baja y octubre hacia la alta. La lluvia aumenta la probabilidad de clase baja (OR 1.82 por cada 121.7 mm) y las semanas de maduración la reducen (OR 0.757 por cada 3.53 semanas). Los signos coinciden con la regresión lineal.

4 Conclusiones

Hallazgos, uso para el Ingenio, mejoras y limitaciones

EN PALABRAS SIMPLES

Los modelos sirven más para planear el conjunto (cuánta caña y azúcar llegarán al molino) que para predecir un lote excepcional.

Hallazgos. El historial del lote es la mejora más valiosa: XGBoost + historial explica cerca del 47 % de la variación de TCH y sacarosa en haciendas no vistas. En clasificación, la logística L1 iguala a modelos complejos y es más estable y fácil de explicar. Los factores clave tienen sentido agronómico: edad, número de corte, variedad y rendimiento previo para el tonelaje; mes de cosecha, madurante y lluvia previa para la sacarosa.

CUATRO CIFRAS REFLEJADAS EN EL ESTUDIO (TÉCNICO)

0.472	**0.465**	**0.434 / 0.480**	**±24 t/ha**
R^2 en prueba para TCH con XGBoost + historial; la regresión lineal obtiene 0.304	R^2 en prueba para %Sac.Caña con el mismo modelo; la regresión lineal obtiene 0.316	F1 macro de la logística L1 (TCH / sacarosa) al clasificar en tres niveles; el azar obtiene ≈0.32	sesgo en los extremos: sobrestima los lotes más bajos y subestima los más altos

Uso para el Ingenio. Estimar la caña y el azúcar que llegarán al molino; concentrar las cosechas de alta sacarosa entre agosto y octubre; aplicar madurante desde cerca de 0.6 L/ha con 7–10 semanas de anticipación; apoyar la renovación de socas y vigilar los lotes con alta probabilidad de rendimiento bajo.

Mejoras. Estaciones meteorológicas por zona, NDVI satelital, sensores de humedad del suelo, muestreos de sacarosa precosecha y registro de fertilización, con monitoreo en tiempo real: ingesta automática, predicción semanal, tablero con alertas y reentrenamiento por zafra.

Limitaciones prácticas y éticas. Algunos predictores solo se conocen cerca del corte; ante años nuevos el R^2 baja a 0.239 en TCH y 0.315 en sacarosa; las predicciones se comprimen hacia la media; IPSA cubre una sola variedad, y los coeficientes muestran asociación, no causalidad. En lo ético, los modelos no deben usarse para sancionar proveedores, las variables de tenencia exigen cuidado para no discriminar, la decisión final debe ser humana, los datos de terceros deben tratarse según la ley colombiana de protección de datos y el uso de madurante debe considerar su impacto ambiental.

Referencias

[1] J. D. Mera Franco y C. Y. Soto Chávez, "Análisis espaciotemporal de las tendencias de precipitación y temperatura en la cuenca del río Cauca y el Pacífico vallecaucano," Corporación Autónoma Regional del Valle del Cauca (CVC), Santiago de Cali, Colombia, Informe técnico, dic. 2024. [En línea]. Disponible: https://ecopedia.cvc.gov.co/sites/default/files/archivosAdjuntos/Informe%20Tendencias%20Precipitacion%20Temperatura.pdf

[2] Cenicaña, "Diagnóstico de la situación de *Diatraea* spp.," *Carta Trimestral*, no. 1, pp. 27–30, 2007. [En línea]. Disponible: https://www.cenicana.org/pdf_privado/carta_trimestral/ct2007/ct1_07/ct1_07_p27-30.pdf

[3] Cenicaña, "Nuevo calendario de temporadas secas y lluviosas en el valle del río Cauca," *Carta Trimestral*, nos. 3 y 4, pp. 4–5, 2010. [En línea]. Disponible: https://www.cenicana.org/pdf_privado/carta_trimestral/ct2010/ct3y4_10/ct3y4_10_p4-5.pdf

[4] scikit-learn developers, "StratifiedGroupKFold," *scikit-learn 1.9 documentation*. [En línea]. Disponible: https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.StratifiedGroupKFold.html

[5] J. G. MacKinnon y M. D. Webb, "The wild bootstrap for few (treated) clusters," *The Econometrics Journal*, vol. 21, no. 2, pp. 114–135, 2018.

[6] C. M. Tfwala y M. E. Dlamini, "Sugarcane ratoon yield decline under three irrigation systems: a case of Ubombo Sugar," *Proc. South African Sugar Technologists' Association*, vol. 95, pp. 85–88, 2023.

[7] A. Plata G. y C. Buenaventura O., "Efecto de la aplicación de tres madurantes químicos en los rendimientos de la caña de azúcar (*Saccharum officinarum* L.) variedad CP 57603," *Acta Agronómica*, vol. 35, no. 4, pp. 97–108, 1985. [En línea]. Disponible: https://revistas.unal.edu.co/index.php/acta_agronomica/article/download/48248/49471

[8] E. Christodoulou, J. Ma, G. S. Collins, E. W. Steyerberg, J. Y. Verbakel y B. Van Calster, "A systematic review shows no performance benefit of machine learning over logistic regression for clinical prediction models," *Journal of Clinical Epidemiology*, vol. 110, pp. 12–22, 2019.