A Anexos

Glosario, tablas completas y figuras complementarias

A.1 Glosario rápido

TCH	Toneladas de caña por hectárea: cuánta caña produce un lote.	**%Sac.Caña**	Porcentaje de sacarosa en la caña: cuánta azúcar trae cada tonelada.
Suerte / hacienda	Suerte es el lote de cultivo; hacienda es la finca que agrupa varias suertes.	**Historial del lote**	TCH y sacarosa del corte anterior del mismo lote, tomado solo de cortes pasados.
Hold-out 80/20	Separar al inicio un 20 % de los datos que solo se usa para la evaluación final.	**Validación agrupada**	Validación cruzada en la que una hacienda (o un mes) nunca está a la vez en ajuste y validación.
RMSE	Raíz del error cuadrático medio; pesa más los errores grandes. Mismas unidades del target.	**MAE**	Error absoluto medio: cuánto se equivoca el modelo en promedio.
R^2	Parte de la variación del target que explica el modelo; 0 equivale a predecir siempre la media.	**F1 macro**	Promedio simple del F1 (balance entre precision y recall) de las tres clases.
Kappa de Cohen	Acuerdo entre predicción y realidad descontando el azar: 0 = azar, 1 = perfecto.	**Regularización L1 / L2**	Penalizaciones a los coeficientes: L1 puede llevarlos a cero (selección de variables); L2 los encoge.
OR (odds ratio)	Cuántas veces se multiplican las odds de una clase cuando la variable aumenta.	**Importancia por permutación**	Cuánto empeora el error al barajar una variable: mide cuánto depende el modelo de ella.
Dependencia parcial	Cómo cambia la predicción promedio cuando se varía una sola variable.	**Bootstrap por hacienda**	Remuestreo de haciendas completas para estimar la incertidumbre de una diferencia.

DÓNDE ESTÁ TODO

El código está en el repositorio del proyecto: **03_comparacion_modelos_suertes.ipynb** (regresión) y **03_comparacion_modelos_ipsa.ipynb** (clasificación). Ambos parten de los datos limpios de **01_eda_suertes.ipynb** y **01_eda_ipsa.ipynb**. Los datos del Ingenio no se publican.

A.2 Tablas complementarias

Tabla A1. Validación cruzada (5 pliegues agrupados por hacienda) de los modelos de regresión

Modelo	TCH RMSE	TCH MAE	TCH R^2	%Sac RMSE	%Sac MAE	%Sac R^2
Media constante	31.16	24.50	−0.005	1.143	0.894	−0.002
Regresión lineal	26.62	20.51	0.267	0.930	0.716	0.335
Ridge (α=316)	26.61	20.51	0.268	0.929	0.715	0.335
Lasso	26.60	20.51	0.268	0.929	0.715	0.336
Random Forest	25.46	19.48	0.329	0.865	0.658	0.424
XGBoost	25.24	19.29	0.341	0.845	0.643	0.450
Reg. lineal + historial	25.67	19.63	0.317	0.915	0.704	0.356
Random Forest + historial	23.99	18.05	0.404	0.862	0.657	0.428
XGBoost + historial	**23.63**	**17.74**	**0.422**	**0.840**	**0.638**	**0.457**

Tabla A2. Clasificación de TCH: métricas macro en validación cruzada (15 pliegues) y prueba

Modelo	Accuracy CV	Precision CV	Recall CV	Accuracy prueba	Precision prueba	Recall prueba
Logística L1 (elegido)	**0.439**	**0.431**	**0.436**	**0.451**	**0.458**	**0.463**
KNN	0.417	0.385	0.376	0.424	0.430	0.382
Random Forest	0.436	0.424	0.425	0.442	0.439	0.454
XGBoost	0.437	0.427	0.430	0.444	0.445	0.458
SVM	0.435	0.429	0.434	0.422	0.428	0.436
Logística + historial	0.462	0.451	0.459	0.476	0.467	0.489
Random Forest + historial	0.457	0.447	0.448	0.491	0.481	0.500
XGBoost + historial	0.470	0.459	0.434	0.476	0.477	0.452
Reg. lineal + umbrales	0.430	0.397	0.374	0.462	0.364	0.396
XGBoost reg. + umbrales	0.426	0.422	0.387	0.400	0.370	0.362

Tabla A3. Clasificación de sacarosa: métricas macro en validación cruzada (15 pliegues) y prueba

Modelo	Accuracy CV	Precision CV	Recall CV	Accuracy prueba	Precision prueba	Recall prueba
Logística L1 (elegido)	**0.493**	**0.469**	**0.448**	**0.533**	**0.531**	**0.482**
KNN	0.472	0.454	0.439	0.478	0.445	0.433
Random Forest	0.466	0.449	0.452	0.498	0.482	0.484
XGBoost	0.465	0.445	0.453	0.522	0.509	0.530
SVM	0.473	0.453	0.431	0.520	0.527	0.476
Logística + historial	0.486	0.464	0.446	0.529	0.522	0.483
Random Forest + historial	0.474	0.453	0.458	0.500	0.483	0.491
XGBoost + historial	0.485	0.469	0.447	0.531	0.533	0.492
Reg. lineal + umbrales	0.470	0.482	0.427	0.511	0.573	0.471
XGBoost reg. + umbrales	0.473	0.482	0.435	0.511	0.535	0.459

A.3 Figuras complementarias

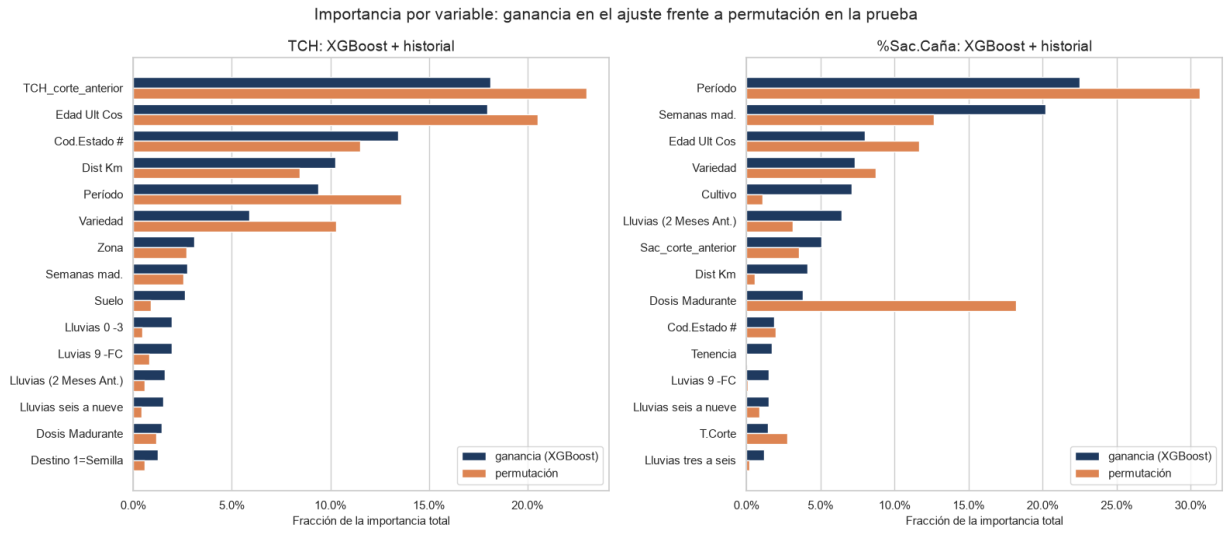


Figura A1. Importancia propia de XGBoost (ganancia total) frente a la permutación, regresión

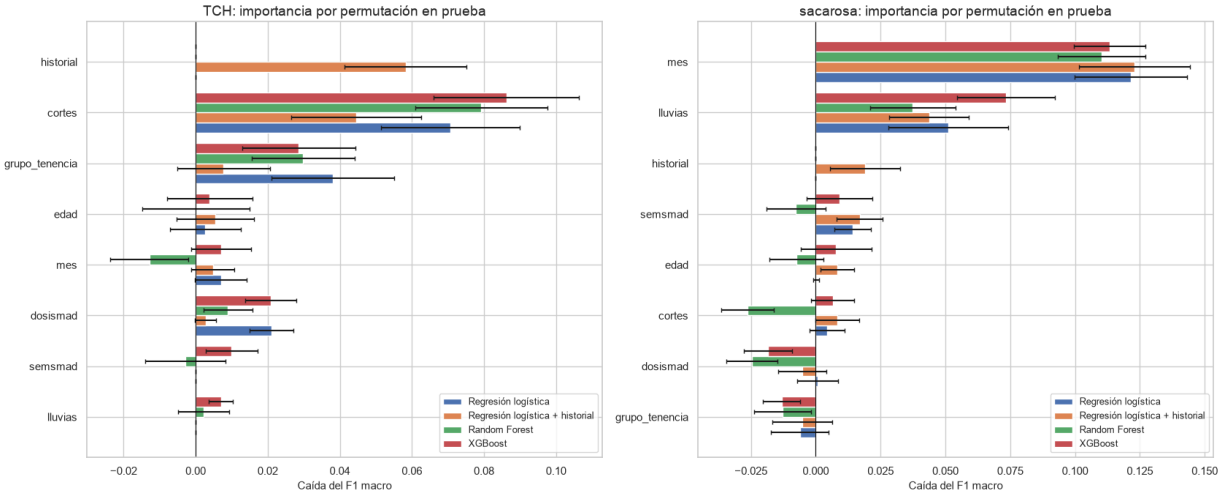


Figura A2. Importancia por permutación en prueba de los clasificadores (IPSA)

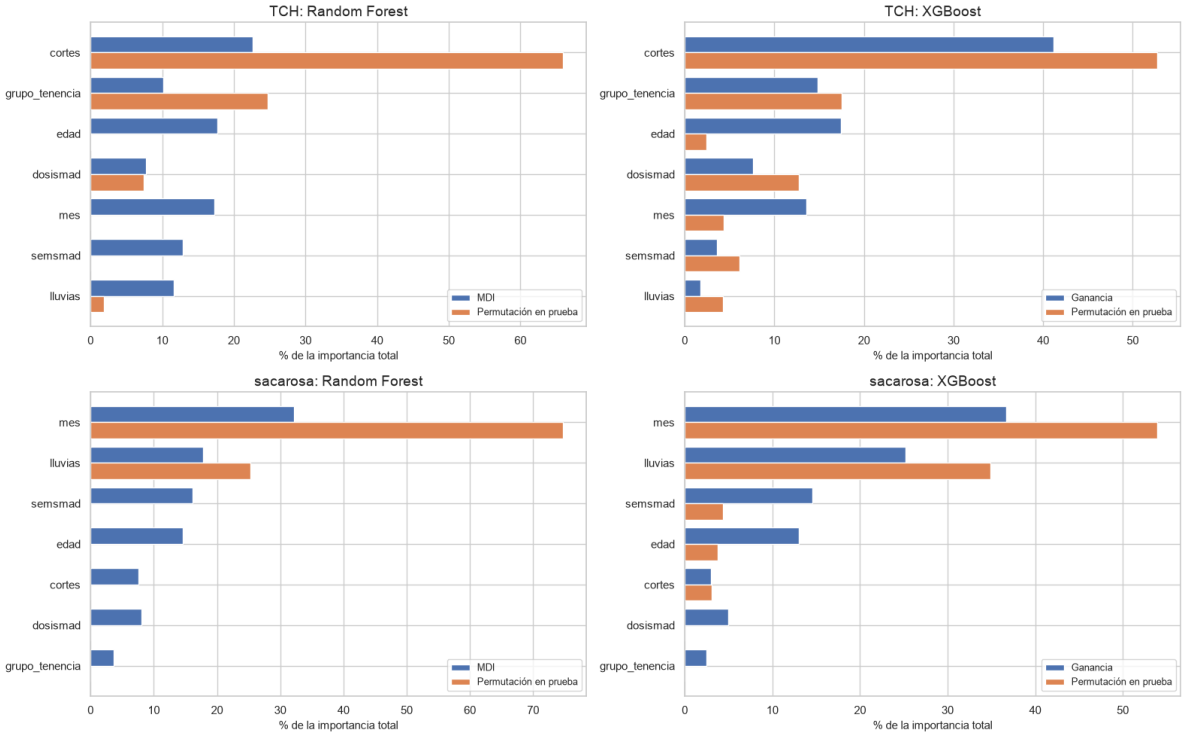


Figura A3. Importancia propia de los árboles (MDI de Random Forest, ganancia de XGBoost) frente a la permutación (IPSA)