

Predicción y clasificación del TCH y la sacarosa de la caña de azúcar en el Ingenio Providencia

Daniel Velasco López, Juan David Martínez Legarda, Juan Esteban Cardona García y Katherin Adriana Camargo Cetina

davelo83.velasco@gmail.com, juandavidmartinezlegarda@gmail.com, juanestebancg2806@gmail.com,
katherinacamargoc@gmail.com

Resumen - Se desarrollaron modelos para anticipar, antes de la cosecha, la productividad (toneladas de caña por hectárea, TCH) y la calidad (porcentaje de sacarosa, %Sac.Caña) de las suertes (lote de cultivo) del Ingenio Providencia. Con el histórico de 21.027 cosechas (2017–2024) se ajustaron regresión lineal múltiple, Ridge, Lasso y Random Forest, con hold-out 80/20, validación cruzada de 5 pliegues y control de la fuga de información. Con 2.187 cosechas de la variedad CC01-1940 se clasificaron ambos objetivos en niveles bajo, medio y alto mediante regresión logística multinomial regularizada y K vecinos más cercanos (KNN), con una partición agrupada por periodo de cosecha. El modelo lineal explica el 32 % de la variación del TCH y el 35 % de la sacarosa en prueba; Random Forest llega a 46 % y 51 %, pero en haciendas o meses de cosecha no vistos su ventaja sobre el lineal cae de 0,14 a entre 0,02 y 0,09 de R^2 . La edad del ciclo, el número de corte, la variedad, la zona y la lluvia temprana explican el tonelaje; la dosis y el tiempo de madurante, la lluvia previa al corte, el mes de cosecha y el manejo orgánico explican la sacarosa. En clasificación, la regresión logística obtuvo un F1 macro de 0,42 a 0,52 y un kappa de 0,15 a 0,27 en prueba, y un umbral de alerta de 0,30 detecta cerca de la mitad de las cosechas de baja sacarosa. Los modelos sirven para priorizar el seguimiento de suertes, no para pronosticar valores exactos.

Índice de Términos - Aprendizaje automático, caña de azúcar, clasificación multinomial, regresión lineal, validación cruzada agrupada.

I. INTRODUCCIÓN

El Ingenio Providencia necesita anticipar, antes de cosechar cada suerte, cuánta caña producirá (TCH, toneladas por hectárea) y qué tan rica en sacarosa será (%Sac.Caña). Ambas variables determinan el azúcar por hectárea, pero responden a factores distintos, y conocerlas con anticipación permite programar la cosecha, dosificar el madurante y priorizar el seguimiento de los lotes de bajo desempeño.

La agroindustria de la caña aporta cerca del 0,6 % del PIB nacional, el 21,1 % del PIB agrícola del Valle del Cauca, con 14 plantas productoras de azúcar y unos 4.500 cultivadores en más de 50 municipios del valle geográfico del río Cauca (Asocaña, s. f.). En 2024 molió 22,1 millones de toneladas de caña y produjo 2,0 millones de toneladas de azúcar (Asocaña, 2025), y genera cerca de 286.000 empleos directos e indirectos (Jaramillo Palacio, 2025). Su productividad es alta pero variable: el TCH nacional cayó de 133 t/ha en 2017 a 102 t/ha en 2023 tras tres años de La Niña (González Vidal, 2024) y se recuperó a 113,9 t/ha en 2024 (Asocaña, 2025).

El TCH depende de la zona agroecológica (suelo y balance hídrico), la variedad, la edad de cosecha y el número de corte: el TCH medio varía cerca de 22 t/ha entre zonas (Carbonell González et al., 2001), cae con cada soca (Posada Contreras y Luna González, 2000) y la variedad CC 01-1940 no debe cosecharse antes de los 12,5 meses (Viveros Valens, 2018). La sacarosa depende de la maduración: la lluvia de los 1–2 meses previos al corte y el exceso de nitrógeno la reducen (Larrahondo y Villegas, 1995), y los madurantes aplicados 6–10 semanas antes de la cosecha la elevan cerca de 7 % en lotes comerciales (Villegas y Arcila, 2003).

Providencia, en El Cerrito, produce cerca del 15 % del azúcar del país y fue pionero en azúcar orgánico (Valora Analitik, 2024). El 60 % de su área es de proveedores (Portafolio, 2023); tiene más de 3.740 ha orgánicas desde 1999 (Semana, 2020), cosecha 100 % mecanizada y en verde, y es Empresa B (Bohórquez Ramírez, 2025). En la literatura, los ensambles de árboles superan a los modelos lineales en la predicción de rendimiento de caña: Random Forest alcanzó R^2 de 0,67 a 0,79 en Australia (Everingham et al., 2016) y de 0,60 a 0,78 con imágenes Sentinel-2 en Brasil (Amaro et al., 2025), y CatBoost obtuvo $R^2 = 0,68$ sobre rendimientos simulados en el valle del río Cauca (Socadagui-Casas et al., 2026); las variables más usadas son

temperatura, lluvia y tipo de suelo (van Klompenburg et al., 2020).

Los objetivos son (1) predecir TCH y %Sac.Caña con información disponible antes de la cosecha, (2) clasificarlos en niveles bajo, medio y alto y (3) identificar las variables de manejo que los explican.

II. MATERIALES Y MÉTODOS

Marco teórico (resumido). La regresión lineal múltiple (OLS) estima efectos aditivos interpretables con pruebas de significancia; Ridge y Lasso penalizan la magnitud de los coeficientes y Lasso además selecciona variables. Random Forest promedia árboles de decisión y captura no linealidades e interacciones. La regresión logística multinomial modela la probabilidad de cada clase con penalización L1 o L2, y KNN asigna la clase mayoritaria de los k vecinos más cercanos.

A. Datos y preprocesamiento

Histórico de suertes (regresión). 21.027 cosechas de 5.799 lotes entre 2017 y 2024; la unidad es un lote (hacienda + suerte) cosechado en un mes. %Sac.Caña falta en 449 filas (2,1 %, sobre todo lotes de semilla) y no se imputa. Se retiraron 26 columnas con 70 % o más de nulos (fertilizantes y estación meteorológica, sin datos antes de febrero de 2022), 5 identificadores, 17 variables de fuga medidas después del corte (TCHM, TAH, Rdto, %ATR, Brix, Pureza y demás laboratorio, además de la vejez) y la lluvia total del ciclo, sustituida por cuatro ventanas (0–3, 3–6, 6–9 meses y 9 meses a cosecha) más la lluvia de los 2 meses previos. Quedaron 22 predictores: edad del ciclo, número de corte, variedad, suelo y zona (categorías raras agrupadas), distancia, dosis y semanas de madurante, lluvias, riego, tipo de corte y quema, cultivo, tenencia, destino, año y mes. La imputación sigue el significado del vacío: dosis nula = 0 (sin madurante), riegos nulos = 0 si el volumen es 0, suelo nulo = «SIN DATO» y distancia, tenencia y cultivo por zona, con estadísticos del entrenamiento. Los ceros de lluvia (36,8 %) son vacíos de medición y se conservan con una bandera. Los atípicos se juzgaron con criterio agronómico: solo se excluyeron del modelo de TCH 355 cosechas de molino con TCH < 60 t/ha. TCH y sacarosa se modelan por separado (correlación de -0,17).

BD_IPSA_1940 (clasificación). 2.187 cosechas de CC01-1940, todas con madurante BONUS 250 EC y cosecha mecanizada en verde, por lo que variedad, producto y tipo de corte son constantes. Se excluyeron por fuga la vejez (horas del corte al molino) y la materia extraña. Los ceros de lluvia (31,3 %) se imputaron con la mediana del mes (en regresión se conservan con una bandera; aquí se imputan porque KNN trataría el cero como una medición real) y se acotó la variable al percentil 99, dentro de un *pipeline*. El mes se codificó con dos armónicos, que capturan el 93 % de la variación estacional de la sacarosa. De 13 predictores candidatos quedaron 11, tras descartar por validación cruzada el año y la bandera de lluvia sin medición: edad, cortes, semanas y dosis de madurante, lluvias, % de *Diatraea*, grupo de tenencia y los armónicos del mes. Las clases se definieron con los umbrales de referencia del Ingenio (TCH < 125, 125–150 y > 150 t/ha; sacarosa < 12,2, 12,2–12,9 y $\geq 13,0$ %) y, como contraste, con terciles del entrenamiento.

B. Modelos, validación y métricas

Regresión. Hold-out aleatorio 80/20 antes de imputar; OLS con revisión de supuestos (Breusch-Pagan, Shapiro-Wilk, Durbin-Watson) y VIF sobre la matriz de diseño; Ridge y Lasso con α elegido por validación cruzada de 5 pliegues; y Random Forest (300 árboles, hoja mínima de 5, contrastados con una grilla por hacienda). Como verificación de robustez se repitió la validación agrupando por hacienda y por periodo de cosecha, se recalcularon los errores estándar del OLS (HC3 y agrupados por lote y por hacienda) y se repitió la validación cruzada con el preprocesamiento dentro de un *Pipeline* reajustado en cada pliegue. Métricas: R^2 , RMSE y MAE.

Clasificación. Las cosechas simultáneas de una hacienda tienen predictores casi idénticos, así que la partición (79,4 % / 20,6 %, 16 periodos en prueba) y la validación cruzada de 5 pliegues se agruparon por periodo de cosecha. Se ajustaron regresión logística multinomial (C entre 0,001 y 100, L1 o L2, con y sin ponderación de clases) y KNN (k impar de 1 a 51, ponderación uniforme o por distancia), eligiendo por F1 macro. Métricas: exactitud, precisión, sensibilidad, F1, kappa de Cohen y AUC, con énfasis en la clase baja. Herramientas: Python 3.13 con pandas, NumPy, statsmodels y scikit-learn, en Jupyter Notebook.

III. RESULTADOS

A. Regresión

La Tabla I resume el desempeño. Ridge y Lasso empatan con el OLS y Random Forest reduce el MAE de prueba en 2,7 t/ha en TCH y en 0,10 puntos en sacarosa (Fig. 1). El 89,7 % de las filas de prueba pertenece a lotes vistos en el entrenamiento; con validación agrupada por hacienda y por periodo, la ventaja del bosque en R^2 baja de 0,135 a 0,041 y 0,087 en TCH, y de 0,137 a 0,085 y 0,019 en sacarosa. Reajustar el preprocesamiento en cada pliegue cambia el R^2 de CV menos de 0,01.

TABLA I
 DESEMPEÑO DE LOS MODELOS DE REGRESIÓN

Modelo	R^2 CV	R^2 prueba	RMSE prueba	MAE prueba	R^2 CV hacienda / periodo
OLS – TCH	0,301	0,324	26,26 t/ha	20,32 t/ha	0,275 / 0,277
Ridge/Lasso – TCH	—	0,323 / 0,324	26,27 / 26,26 t/ha	20,32 t/ha	—
RF – TCH	0,437	0,457	23,52 t/ha	17,57 t/ha	0,315 / 0,365
OLS – %Sac.	0,342	0,350	0,907 pts	0,706 pts	0,325 / 0,298
Ridge/Lasso – %Sac.	—	0,350 / 0,344	0,907 / 0,912 pts	0,706 / 0,709 pts	—
RF – %Sac.	0,480	0,505	0,792 pts	0,609 pts	0,410 / 0,317

CV: validación cruzada de 5 pliegues sobre el entrenamiento. Última columna: GroupKFold por hacienda / por periodo (RF de 150 árboles).




Fig. 1. Valores reales frente a predichos en el conjunto de prueba (OLS en gris, Random Forest en azul). Ambos modelos comprimen los extremos hacia la media.

La Tabla II presenta los coeficientes del OLS. Salvo los marcados como no significativos, todos tienen $p < 0,05$; con errores robustos o agrupados la pierden los marcados con † o ‡ y la lluvia de 9 meses a cosecha en TCH. Los residuos son heterocedásticos (Breusch-Pagan LM = 1.299 en TCH y 671 en sacarosa) y los cortes de un mismo lote están autocorrelacionados (Durbin-Watson = 1,36 y 1,77). En sacarosa, septiembre y octubre suman 0,65 puntos frente a enero y junio resta 0,49. La Fig. 2 muestra la importancia de variables del Random Forest.

TABLA II
 COEFICIENTES SELECCIONADOS DEL OLS (ENTRENAMIENTO)

Predictor	TCH (t/ha)	%Sac.Caña (pts)
Edad del ciclo (por mes)	+4,59	+0,022
Número de corte (por corte)	-0,63	+0,007 ‡
Dosis de madurante (por L/ha)	+2,20	+0,52
Semanas de madurante (por semana)	-0,88	+0,015
Lluvia 0–3 meses (por 100 mm)	-1,6	+0,02
Lluvia 2 meses antes del corte (por 100 mm)	+0,9 †	-0,13
Cultivo orgánico (frente a normal)	+5,3 ‡	-1,08
Año (tendencia desde 2017)	-3,29	n. s.
Destino semilla (frente a molino)	-21,7	n. s.
Variedad CC05-430	+14,3	-0,40

$p < 0,05$ con errores clásicos; n. s.: no significativo. † n. s. con HC3 o agrupados. ‡ n. s. agrupando por hacienda.




Fig. 2. Importancia de variables del Random Forest (ocho primeras).

B. Clasificación

La regresión logística superó a los clasificadores de referencia en los cuatro casos (F1 macro de 0,30–0,36 sin predictores) y fue igual o mejor que KNN (Tabla III). El F1 macro de prueba difiere del de validación cruzada entre $-0,04$ y $+0,07$. En TCH, la clase media es la de menor F1 con las dos definiciones de clase y entre 19 % y 34 % de los errores confunden las clases extremas; en sacarosa, entre 13 % y 25 % (Fig. 3). Con los umbrales del Ingenio, la regla de la clase más probable detecta el 23,7 % de las cosechas de baja sacarosa; un umbral de alerta de 0,30 eleva la detección a 49,5 % con 47,5 % de alertas correctas y alerta al 22,4 % de las cosechas.

TABLA III
DESEMPEÑO DE CLASIFICACIÓN (VALIDACIÓN CRUZADA Y PRUEBA: 16 PERIODOS, 450 COSECHAS)

Objetivo – clases	Modelo	F1 CV	Exact.	F1 macro	Kappa	Prec. bajo	Sens. bajo	AUC bajo
TCH – Ingenio	Logística	0,422	0,433	0,416	0,149	0,354	0,500	0,674
TCH – Ingenio	KNN (k = 13)	0,378	0,416	0,377	0,071	0,452	0,186	0,615
TCH – terciles	Logística	0,446	0,436	0,426	0,153	0,496	0,446	0,658
TCH – terciles	KNN (k = 37)	0,429	0,396	0,384	0,093	0,454	0,399	0,596
Sacarosa – Ingenio	Logística	0,448	0,504	0,457	0,203	0,511	0,237	0,773
Sacarosa – Ingenio	KNN (k = 9)	0,443	0,507	0,473	0,223	0,406	0,268	0,711
Sacarosa – terciles	Logística	0,452	0,516	0,518	0,274	0,642	0,555	0,771
Sacarosa – terciles	KNN (k = 51)	0,468	0,484	0,481	0,227	0,589	0,555	0,719




Fig. 3. Matrices de confusión de la regresión logística en prueba, con los umbrales del Ingenio, normalizadas por la clase real.

IV. DISCUSIÓN

Los signos del modelo lineal coinciden con la literatura: más edad de ciclo suma tonelaje y cada soca lo resta (Posada Contreras y Luna González, 2000; Viveros Valens, 2018), la dosis de madurante eleva la sacarosa y más semanas de exposición reducen algo el tonelaje (Villegas y Arcila, 2003), y la lluvia al final del ciclo diluye la sacarosa (Larrahondo y Villegas, 1995). El manejo orgánico resta 1,08 puntos de sacarosa porque solo el 0,49 % de esos lotes recibe madurante, frente al 55,45 % de los convencionales: es el costo en calidad de una práctica de sostenibilidad del Ingenio. La tendencia negativa del año ($-3,29$ t/ha) es parcialmente coherente con la caída nacional entre 2017 y 2023 asociada a La Niña (González Vidal, 2024).

Random Forest mejora la predicción porque captura la caída no lineal del TCH con los cortes, la heterocedasticidad y la interacción entre lluvia temprana y variedad; es el patrón reportado en la literatura (Everingham et al., 2016; Socadagui-Casas et al., 2026). Sin embargo, buena parte de su ventaja proviene de reconocer fincas y meses ya vistos: la distancia al ingenio tiene un único valor en 922 de 923 haciendas y quitarla reduce el R^2 del bosque en 0,042 por filas, pero solo en 0,016 en fincas nuevas; su importancia en la Fig. 2 es sobre todo memoria de finca. Por eso el OLS se conserva para interpretar y el bosque para predecir, con el desempeño agrupado como expectativa realista en fincas o meses nuevos.

En clasificación, la partición agrupada por periodo fue decisiva: con pliegues que admiten cosechas simultáneas, KNN parecía superar a la logística hasta en 0,07 de F1 macro, ventaja que desaparece al evaluar periodos no vistos. La logística se prefiere por ordenar mejor el riesgo de las cosechas bajas (AUC de hasta 0,77) y por ser interpretable. La dificultad de la clase media en TCH se mantiene con umbrales del Ingenio y con terciles, lo que apunta a la falta de predictores de tonelaje y no a la definición de las clases.

Limitaciones. Falta la fertilización (80–100 % de nulos) y el clima de estación antes de 2022; entre 31 % y 37 % de las lluvias no tiene medición; el hold-out de regresión es aleatorio por filas, por lo que sus métricas

son optimistas para fincas o meses nuevos; el % de *Diatraea* se mide en la cosecha (quitarlo cambia el F1 macro menos de 0,01); BD_IPSA_1940 solo representa CC01-1940 madurada y cosechada en verde; y los códigos de tenencia no están documentados. Los coeficientes describen asociaciones, no efectos causales.

V. CONCLUSIONES

Con información disponible antes de la cosecha se explica cerca de un tercio de la variación del TCH y de la sacarosa con un modelo lineal interpretable, y entre 32 % y 51 % con Random Forest según se evalúe en fincas o meses nuevos o en lotes vistos. Esto significa que el Ingenio podría priorizar la renovación de socas con muchos cortes, evitar cosechar ciclos cortos, definir la ventana de madurante según se priorice tonelaje o calidad, y reforzar el seguimiento de maduración en las cosechas de mayo a julio y tras lluvias intensas. El clasificador de sacarosa, con un umbral de 0,30, permitiría revisar una de cada cinco suertes para detectar cerca de la mitad de las de baja sacarosa, si una cosecha baja no detectada cuesta dos o tres veces más que una revisión innecesaria.

Como trabajo futuro se propone: validación temporal (entrenar con años anteriores y evaluar en los siguientes); incorporar fertilización, suelo, lluvia por etapas con rezago respecto a la siembra e índices ENSO; índices de vegetación Sentinel-2 durante el ciclo (Amaro et al., 2025); una regresión logística ordinal; y un monitoreo mensual de las suertes programadas con la lluvia actualizada. Éticamente, el modelo debe apoyar y no sustituir el criterio agronómico, y el uso de datos de proveedores y de la tenencia exige transparencia para no asignar seguimiento según la forma de tenencia en lugar de las condiciones del cultivo.

REFERENCIAS

- Amaro, R. P., Christina, M., Todoroff, P., Le Maire, G., Fiorio, P. R., Pereira, E. de C., & Luciano, A. C. dos S. (2025). Regional model to predict sugarcane yield using Sentinel-2 imagery in São Paulo State, Brazil. *Sugar Tech*, 27(1), 108–118. <https://doi.org/10.1007/s12355-024-01468-z>
- Asocaña. (s. f.). *Sector agroindustrial de la caña en Colombia*. <https://www.asocana.org/publico/info.aspx?Cid=215>
- Asocaña. (2025). *Informe anual 2024-2025*. Asociación de Cultivadores de Caña de Azúcar de Colombia.
- Bohórquez Ramírez, C. (2025, 26 de agosto). Este es el ingenio azucarero que opera en el corazón del Valle del Cauca, siendo el único certificado como Empresa B de todo Colombia. *El Tiempo*.
- Carbonell González, J., Amaya Estévez, Á., Ortiz Uribe, B. V., Torres Aguas, J. S., Quintero Durán, R., & Isaacs Echeverry, C. H. (2001). *Zonificación agroecológica para el cultivo de caña de azúcar en el valle del río Cauca: Tercera aproximación* (Serie Técnica No. 29). Cenicaña.
- Everingham, Y., Sexton, J., Skocaj, D., & Inman-Bamber, G. (2016). Accurate prediction of sugarcane yield using a random forest algorithm. *Agronomy for Sustainable Development*, 36(2), Artículo 27. <https://doi.org/10.1007/s13593-016-0364-z>
- González Vidal, X. (2024, 5 de septiembre). Productividad de la caña de azúcar en Colombia duplica el promedio mundial. *Redagráfica*.
- Jaramillo Palacio, C. (2025, 26 de febrero). El sector de la caña genera 286.000 empleos entre directos e indirectos en Colombia. *Agronegocios*.
- Larrahondo, J. E., & Villegas, F. (1995). Control y características de maduración. En C. Cassalet Dávila, J. Torres Aguas, & C. Isaacs Echeverri (Eds.), *El cultivo de la caña en la zona azucarera de Colombia* (pp. 297–313). Cenicaña.
- Portafolio. (2023, 9 de agosto). Rentabilidad, foco de la estrategia de Providencia. *Portafolio*.
- Posada Contreras, C., & Luna González, C. A. (2000). *Comportamiento comercial de la caña de azúcar cosechada en el valle del río Cauca durante 1999* (Serie Técnica No. 28). Cenicaña.
- Semana. (2020, 26 de julio). Ingenio Providencia, un motor de sostenibilidad a base de azúcar orgánico. *Semana*.
- Socadagui-Casas, D. A., Rodríguez-Vasquez, A. F., Rubiano-Sanabria, Y., Jimenez-Gutierrez, D. M., & Socadagui-Casas, S. R. (2026). Spatial modeling of sugarcane yield using machine learning approaches. *Sugar Tech*, 28(2), 675–685. <https://doi.org/10.1007/s12355-026-01736-0>
- Valora Analitik. (2024, 20 de abril). Ingenio Providencia produce el 15 % del azúcar en Colombia. *Yahoo Finanzas*.
- van Klompenburg, T., Kassahun, A., & Catal, C. (2020). Crop yield prediction using machine learning: A systematic literature review. *Computers and Electronics in Agriculture*, 177, Artículo 105709. <https://doi.org/10.1016/j.compag.2020.105709>
- Villegas, F., & Arcila, J. (2003). *Maduradores en caña de azúcar: Manual de procedimientos y normas para su aplicación* (Serie Técnica No. 32). Cenicaña.
- Viveros Valens, C. A. (Ed.). (2018). *Características agronómicas y de productividad de la variedad Cenicaña Colombia (CC) 01-1940* (Serie Técnica No. 40). Cenicaña.